计量经济学讲义

多元回归分析：估计

Lectio & AutoClaw

2026 年 4 月 20 日

多元回归分析：估计

马琳

UIBE

2026 年 4 月 2 日

来源/作者：马琳 / 对外经济贸易大学（UIBE）
发布日期：2026 年 4 月 2 日
篇幅：33 页 Beamer 课件

目录

1 为什么要用多元回归？ 2

1.1 一元回归的局限 2

1.2 多元回归的优势 2

1.3 偏回归系数 3

1.4 Feynman Summary 3

2 普通最小二乘法（OLS）：操作与解释 3

2.1 OLS 估计量的定义 3

2.2 矩阵形式与解析解 4

2.3 矩估计方法（MM）（了解） 5

2.4 对 OLS 回归方程的解释 5

2.4.1 OLS 拟合值和残差的性质 5

2.4.2 ”排除其他变量影响”的解释（Frisch-Waugh 定理） 5

2.4.3 简单回归 vs 多元回归估计值的比较 6

2.5 拟合优度：R^2 与调整 R^2 7

2.5.1 R^2（决定系数） 7

2.5.2 调整 R^2（Adjusted R^2） 7

2.6 Feynman Summary 8

3 OLS 估计量的期望值（无偏性） 8

3.1 经典假定体系（MLR.1–MLR.4） 8

3.1.1 MLR.3：不存在完全共线性 8

3.1.2 MLR.4：零条件均值 9

3.2 OLS 无偏性定理 9

3.3 Feynman Summary 9

4 OLS 估计量的方差 9

4.1 同方差假定（MLR.5） 9

4.2 OLS 估计量的方差公式 10

4.3 关于多重共线性的深入讨论 10

4.4 σ^2 的估计：回归标准误 11

4.5 高斯-马尔科夫定理 11

4.6 Feynman Summary 11

5 总结与知识框架 12

5.1 核心知识图谱 12

5.2 关键公式速查 12

6 苏格拉底对话 12

1 为什么要用多元回归？

1.1 一元回归的局限

在实际研究中，我们往往关心的是：在**其他因素不变**的情况下，x 对 y 的影响。然而，一元回归模型很难满足”所有其他影响 y 的因素都与 x 无关”这一强假设。

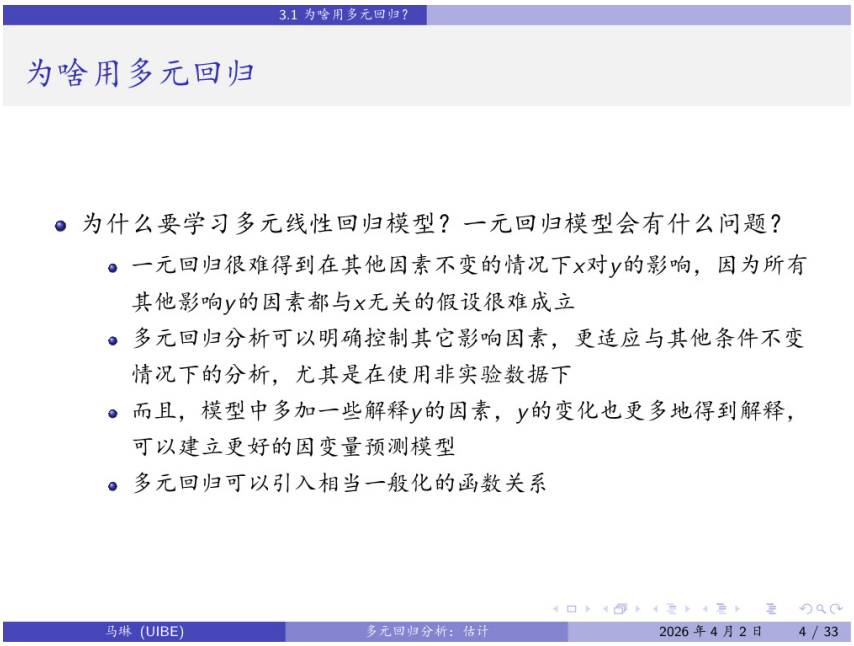

图 1: 为什么要用多元回归?（第 4 页）

- 一元回归无法剥离混杂因素（confounders），导致对因果效应的估计有偏
- 在使用非实验数据（观测数据）时尤其严重

1.2 多元回归的优势

多元线性回归方程的一般形式：

$$y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \cdots + \beta_k x_{ki} + u_i, \quad i = 1, \ldots, n$$

其中：

- y：因变量（dependent variable）
- $x_1, x_2, \ldots, x_k$：k 个自变量
- u：误差项（error term）/ 干扰项（disturbance）
- β_0：截距项（intercept）

多元回归的三大优势

1. **控制变量（Ceteris Paribus）**：明确控制其他影响因素，实现”在其他条件不变下”的分析，特别适用于非实验数据
2. **解释力提升**：增加解释变量使 y 的变异得到更充分解释，可建立更好的预测模型
3. **函数形式灵活**：可引入一般化函数关系（如 $\text{cons} = \beta_0 + \beta_1 \text{inc} + \beta_2 \text{inc}^2 + u$）

1.3 偏回归系数

β_j 称为变量 x_j 的**偏回归系数**（Partial Regression Coefficient），表示当其他变量都不变时，x_j 的单位变化对 y 的预期影响：

$$\frac{\partial E(y_i \mid x_{1i}, x_{2i}, \ldots, x_{ki})}{\partial x_j} = \beta_j$$

关键假设

$$E(u \mid x_1, x_2, \ldots, x_k) = 0$$

即误差项的条件期望为零——这是保证 OLS 无偏性的核心假设（外生性假设）。

经典例子——工资方程：

$$\text{wage} = \beta_0 + \beta_1 \text{educ} + \beta_2 \text{exper} + u$$

加入工作经历 exper 后，β_1 度量的是在**控制工作经历不变**的情况下，教育对工资的影响。

1.4 Feynman Summary

想象你想知道”多读一年书能多赚多少钱”。如果你只比较不同教育水平的人的收入（一元回归），你会发现受教育多的人收入高——但也许是因为他们工作年限也更长。多元回归就像一个公平的比较器：它让所有人都有相同的工作年限，然后再看教育和收入的关系。这就是”控制其他变量不变”的直觉。

2 普通最小二乘法（OLS）：操作与解释

2.1 OLS 估计量的定义

给定 n 个观测值 $(x_{1i}, x_{2i}, \ldots, x_{ki}, y_i)$，OLS 通过**最小化残差平方和**来估计参数：

$$\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots + \hat{\beta}_k x_{ki}$$

残差 $\hat{u}_i = y_i - \hat{y}_i$，残差平方和为：

$$\sum_{i=1}^{n} \hat{u}_i^2 = \sum_{i=1}^{n} \left[y_i - (\hat{\beta}_0 + \hat{\beta}_1 x_{1i} + \cdots + \hat{\beta}_k x_{ki}) \right]^2$$

OLS 估计量定义为：

$$\boxed{(\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_k) = \arg\min_{\beta} \sum_{i=1}^{n} [y_i - (\beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki})]^2}$$

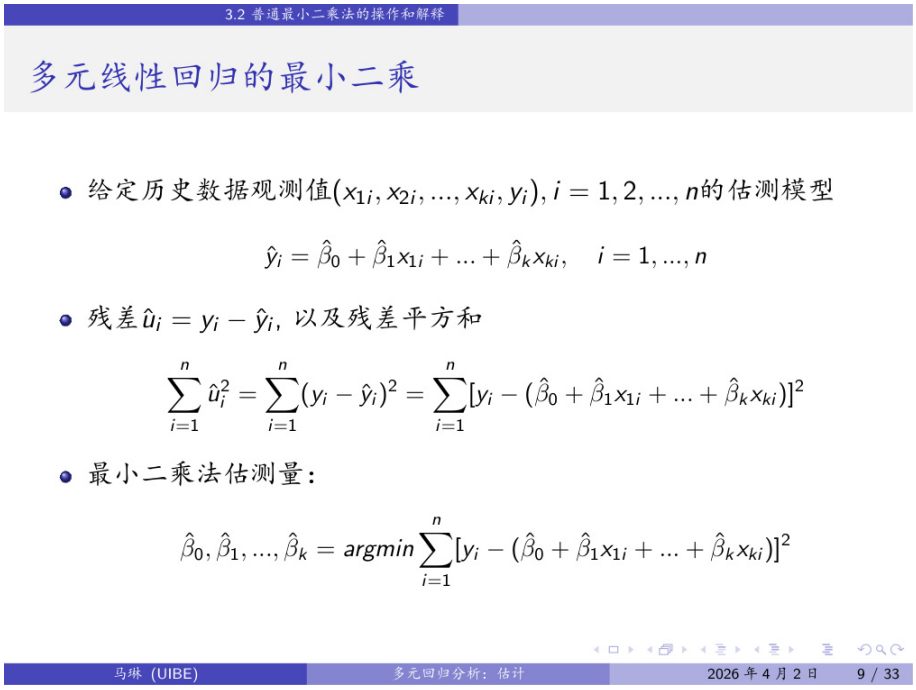

图 2: 多元线性回归的最小二乘法（第 9 页）

2.2 矩阵形式与解析解

令 $\mathbf{x}_j = [x_{j1}, x_{j2}, \ldots, x_{jn}]^T$，$\hat{\boldsymbol{\beta}} = [\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_k]^T$，设计矩阵 $X = [\mathbf{1}, \mathbf{x}_1, \ldots, \mathbf{x}_k]$，$Y = [y_1, y_2, \ldots, y_n]^T$。矩阵形式的回归模型：$Y = X\boldsymbol{\beta} + u$

OLS 闭式解（正规方程组）

$$\boxed{\hat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T Y}$$

存在条件：$X^T X$ 可逆（即不存在完全多重共线性，且 $n > k + 1$）。

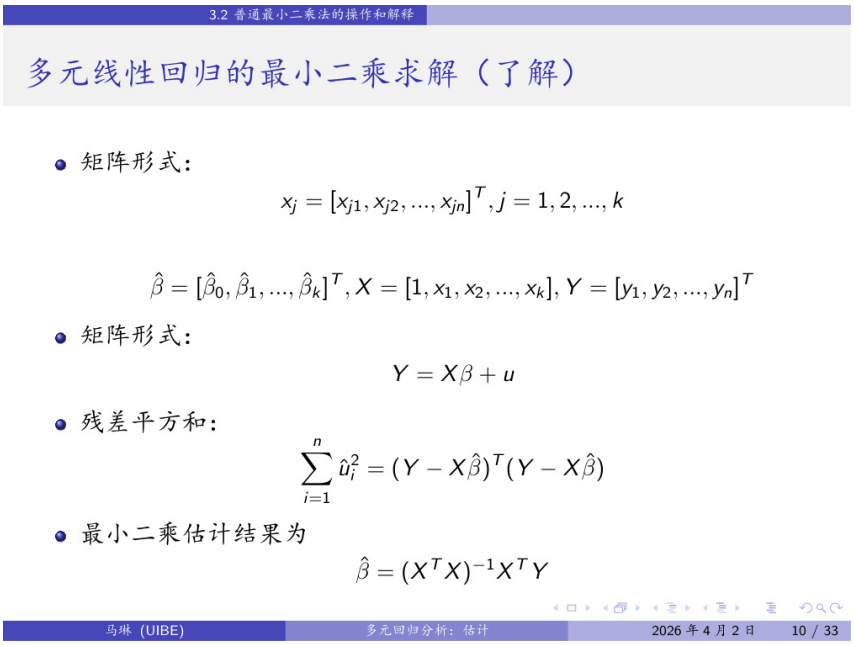

图 3: OLS 矩阵求解（第 10 页）

2.3 矩估计方法（MM）（了解）

另一种推导思路：由 $Y = X\beta + u$ 出发，左乘 X^T 得 $X^TY = X^TX\beta + X^Tu$。取期望后利用 $E(X^Tu) = 0$ 得到矩条件，用样本矩代替总体矩即得正规方程组。MM 估计量与 OLS 估计量**完全等价**。

2.4 对 OLS 回归方程的解释

回归方程可用变化量表示：

$$\Delta\hat{y} = \hat{\beta}_1\Delta x_1 + \hat{\beta}_2\Delta x_2 + \cdots + \hat{\beta}_k\Delta x_k$$

$\hat{\beta}_1$ 度量的是在**所有其他条件不变**的情况下，x_1 提高一个单位导致的 $\hat{y}$ 的变化。

2.4.1 OLS 拟合值和残差的性质

1. 残差的样本均值为零：$\bar{y} = \bar{\hat{y}}$
2. 每个自变量与 OLS 残差之间的样本协方差为零
3. 点 $(\bar{x}_1, \bar{x}_2, \ldots, \bar{x}_k, \bar{y})$ 总在 OLS 回归线上

$$\bar{y} = \hat{\beta}_0 + \hat{\beta}_1\bar{x}_1 + \hat{\beta}_2\bar{x}_2 + \cdots + \hat{\beta}_k\bar{x}_k$$

2.4.2 ”排除其他变量影响”的解释（Frisch-Waugh 定理）

考虑 $k = 2$ 的情形：$\hat{y} = \hat{\beta}_0 + \hat{\beta}_1x_1 + \hat{\beta}_2x_2$

$$\hat{\beta}_1 = \frac{\sum_{i=1}^{n} \hat{r}_{i1}y_i}{\sum_{i=1}^{n} \hat{r}_{i1}^2}$$

其中 $\hat{r}_{i1}$ 是将 x_1 对 x_2 进行简单回归得到的 OLS 残差——即 x_1 中**排除了 x_2 影响之后的部分**。

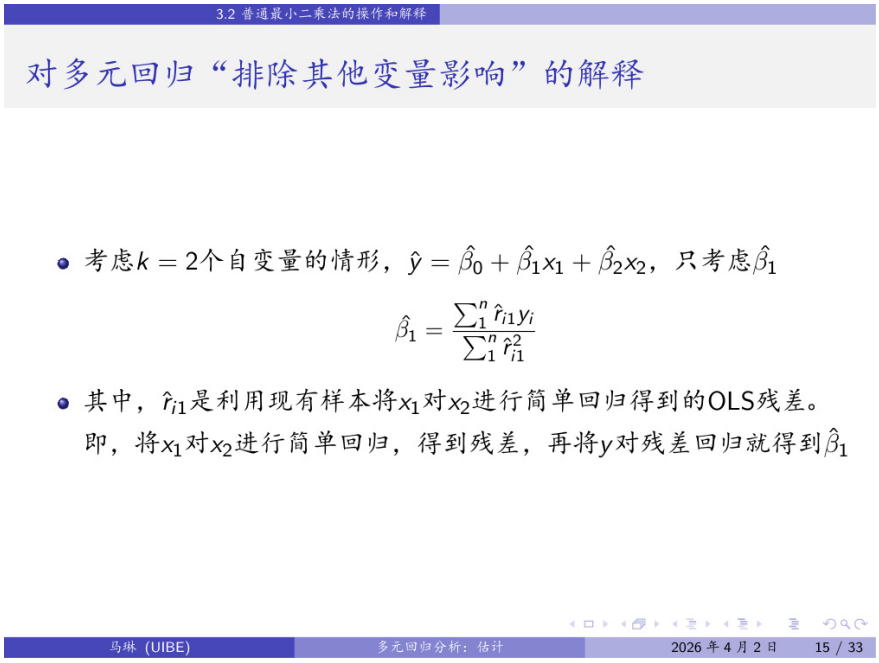

图 4: 排除其他变量影响的解释 / Frisch-Waugh 定理（第 15 页）

Frisch-Waov 定理（弗里施-沃定理）

在含有 k 个解释变量的模型中，$\hat{\beta}_1$ 等价于以下两步操作的结果：

1. 将 x_1 对 $x_2, \ldots, x_k$ 回归，得到残差 $\hat{r}_{i1}$（即 x_1 中与其他自变量正交的部分）
2. 将 y 对 $\hat{r}_{i1}$ 回归，所得斜率即为 $\hat{\beta}_1$

这精确地刻画了”偏回归系数”中”偏”的含义。

2.4.3 简单回归 vs 多元回归估计值的比较

一元回归：$\tilde{y}=\tilde{\beta}_0+\tilde{\beta}_1x_1$，其中 $\tilde{\beta}_1=\dfrac{\sum(x_1-\bar{x}_1)(y-\bar{y})}{\sum(x_1-\bar{x}_1)^2}$

二元回归：$\hat{y}=\hat{\beta}_0+\hat{\beta}_1x_1+\hat{\beta}_2x_2$

可以证明：$\tilde{\beta}_1=\hat{\beta}_1+\hat{\beta}_2\tilde{\delta}_1$，其中 $\tilde{\delta}_1$ 为 x_2 对 x_1 的回归系数。

重要结论

只有当 $\hat{\beta}_2=0$ 或 $\tilde{\delta}_1=0$（即 x_1 与 x_2 不相关）时，一元和多元回归的估计结果才相等。否则，**遗漏变量偏差**（Omitted Variable Bias）会导致一元回归估计有偏。

2.5 拟合优度：R^2 与调整 R^2

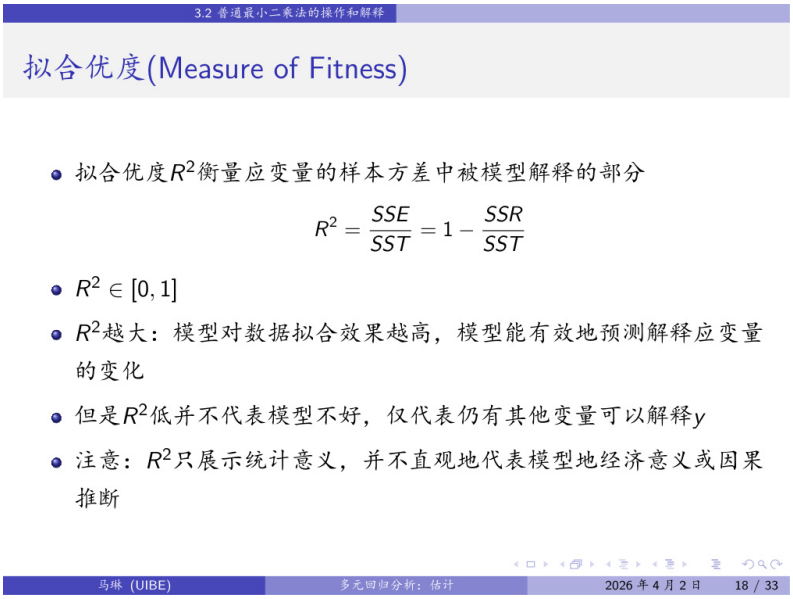

图 5: 拟合优度 Measure of Fitness（第 18 页）

2.5.1 R^2（决定系数）

$$R^2 = \frac{\text{SSE}}{\text{SST}} = 1 - \frac{\text{SSR}}{\text{SST}}, \quad R^2 \in [0,1]$$

- SSE（Explained Sum of Squares）：被模型解释的变异
- SSR（Residual Sum of Squares）：未被解释的残差变异
- SST（Total Sum of Squares）：总变异

R^2 越大 $\Rightarrow$ 模型拟合效果越好。但需注意：

R^2 的陷阱

- R^2 低不代表模型不好，仅代表仍有其他变量可以解释 y
- R^2 只展示统计意义，不直接代表经济意义或因果推断有效性
- 加入任何变量（即使无关变量）都会提高 R^2！

2.5.2 调整 R^2（Adjusted R^2）

为了惩罚无关变量的加入，引入调整 R^2：

$$\bar{R}^2 = 1 - \frac{\text{SSR}/(n-k-1)}{\text{SST}/(n-1)} = 1 - (1-R^2)\frac{n-1}{n-k-1}$$

R^2 不能告诉你：变量是否统计显著、是否为真实原因、是否存在遗漏变量偏差、是否选择了最优变量集。

2.6 Feynman Summary

OLS 就像给一堆散点找一条最佳穿过它们的”平均路径”。多元回归中的每个系数告诉你：”如果只改变这一个变量、保持其他所有变量不动，y 会怎么变。”R^2 告诉你这条路径能解释多少数据的波动——但它不能告诉你这条路是不是”对的”，只能告诉你它拟合得好不好。

3 OLS 估计量的期望值（无偏性）

3.1 经典假定体系（MLR.1–MLR.4）

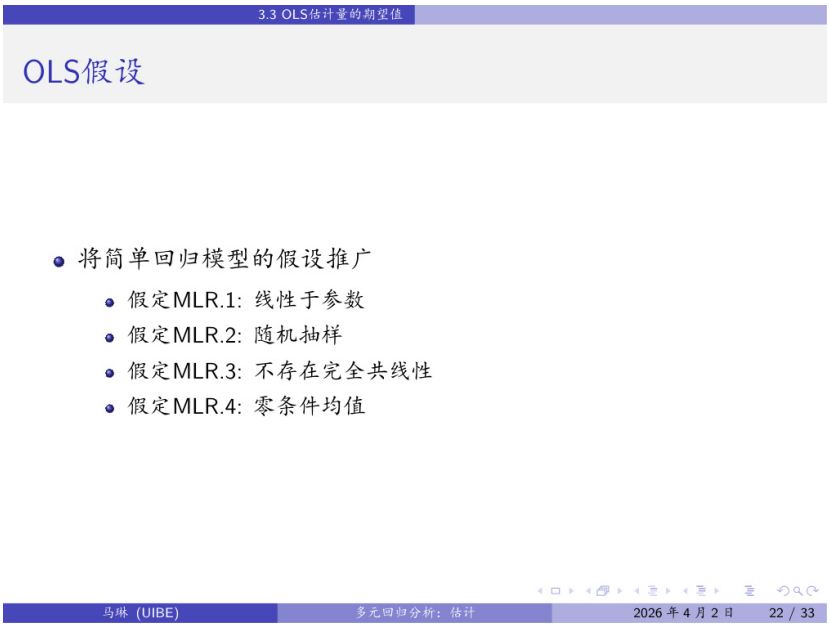

图 6: OLS 假设体系（第 22 页）

表 1: OLS 经典假定

假定	内容
MLR.1（线性于参数）	模型关于参数是线性的：$y = \beta_0 + \beta_1 x_1 + \cdots + \beta_k x_k + u$
MLR.2（随机抽样）	样本为随机抽样，观测值 i.i.d.
MLR.3（不存在完全共线性）	自变量之间无严格线性关系（X 列满秩），且 $n \geq k+1$
MLR.4（零条件均值）	$E(u \mid x_1, \ldots, x_k) = 0$

3.1.1 MLR.3：不存在完全共线性

没有一个自变量是常数，自变量之间也不存在严格的线性关系。如果一个自变量可以被其他自变量线性表出，就遇到了**完全共线性问题**，无法用 OLS 估计。

注意：该假定**允许**自变量之间存在相关关系，只是不能完全相关。

例子：选举模型 $\text{voteA} = \beta_0 + \beta_1 \text{expendA} + \beta_2 \text{expendB} + \beta_3 \text{totexpend} + u$ 中，$\text{totexpend} = \text{expendA} + \text{expendB}$，导致完全共线性。

3.1.2 MLR.4：零条件均值

给定解释变量的任何值，误差项的条件期望为零。当 MLR.4 成立时，称 x 为**外生解释变量**；否则称为**内生解释变量**。

内生性是 OLS 有偏的最常见来源（如遗漏变量、测量误差、双向因果等）。

3.2 OLS 无偏性定理

定理（OLS 的无偏性）

在假定 MLR.1 至 MLR.4 下，对所有 $j = 0, 1, \ldots, k$：

$$\boxed{E(\hat{\beta}_j) = \beta_j}$$

即 OLS 估计量是总体参数的**无偏估计量**。

无偏性的直观含义：如果我们反复抽取样本并每次计算 $\hat{\beta}_j$，这些估计值的平均值将收敛到真实的总体参数 β_j。

3.3 Feynman Summary

无偏性就像射箭——你不一定每次都中靶心，但如果你的瞄准系统没有系统性偏差（比如不会总是偏右或偏高），那么大量射击的平均位置就在靶心。OLS 的四个假定就是确保" 瞄准镜没有系统性偏差" 的条件。其中最关键也最难满足的是零条件均值——你的误差项不能跟任何一个解释变量" 勾结" 在一起。

4 OLS 估计量的方差

4.1 同方差假定（MLR.5）

MLR.5（同方差性）：给定解释变量的任何值，误差项具有相同的方差：

$$\mathrm{Var}(u \mid x_1, \ldots, x_k) = \sigma^2$$

假定 MLR.1 到 MLR.5 合称**高斯-马尔科夫假定**（Gauss-Markov Assumptions）。

4.2 OLS 估计量的方差公式

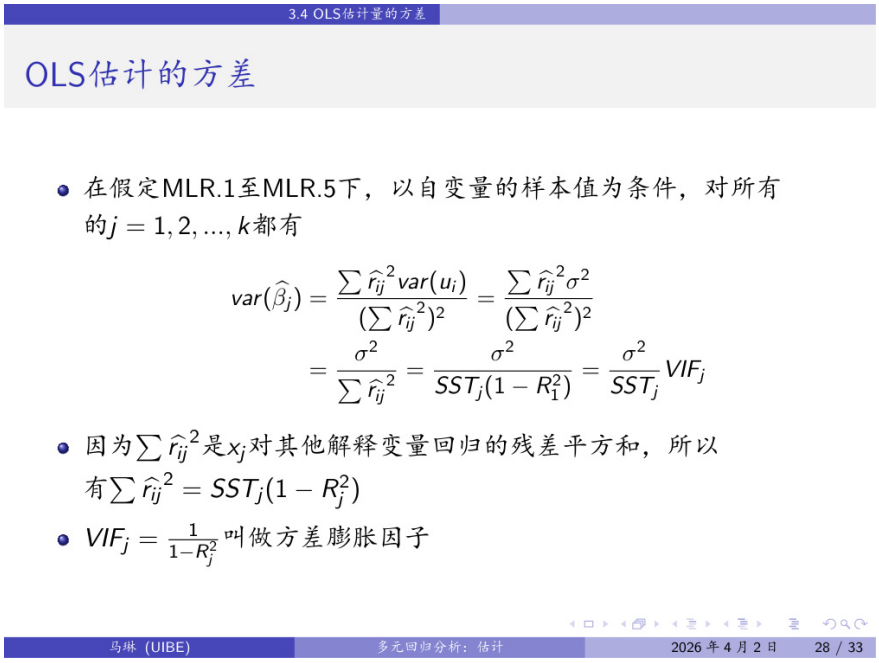

图 7: OLS 估计的方差（第 28 页）

在 MLR.1–MLR.5 下：

$$\mathrm{var}(\hat{\beta}_j) = \frac{\sigma^2}{\sum \hat{r}_{ij}^2} = \frac{\sigma^2}{\mathrm{SST}_j(1-R_j^2)} = \frac{\sigma^2}{\mathrm{SST}_j} \cdot \mathrm{VIF}_j$$

其中：

- $\sum \hat{r}_{ij}^2 = \mathrm{SST}_j(1-R_j^2)$：$x_j$ 对其他解释变量回归后的残差平方和
- $\mathrm{SST}_j = \sum (x_{ij} - \bar{x}_j)^2$：$x_j$ 的总样本波动
- R_j^2：x_j 对其余所有自变量做辅助回归的决定系数
- $\mathrm{VIF}_j = \dfrac{1}{1-R_j^2}$：**方差膨胀因子**（Variance Inflation Factor）

4.3 关于多重共线性的深入讨论

重要区分

完全共线性（违反 MLR.3）：OLS 无法估计（矩阵不可逆）
近似（不完全）多重共线性：不违背任何假定，但会使方差增大、估计精度下降

近似多重共线性的应对策略：

- 增加样本容量（提高 SST_j）
- 某些变量间高度相关可能不影响其他参数的估计精度（如歧视例中，收入/住房价值/信誉高度相关但不影响种族系数的方差）

4.4 σ^2 的估计：回归标准误

σ^2 的无偏估计量：

$$\hat{\sigma}^2 = \frac{\sum \hat{u}_i^2}{n-k-1}$$

$\hat{\sigma}$ 称为**回归标准误**（Standard Error of Regression, SER），度量了 y 的分布在回归线周围的离散程度。

斜率的标准误：

$$\mathrm{se}(\hat{\beta}_j) = \frac{\hat{\sigma}}{\sqrt{\mathrm{SST}_j(1-R_j^2)}}$$

4.5 高斯-马尔科夫定理

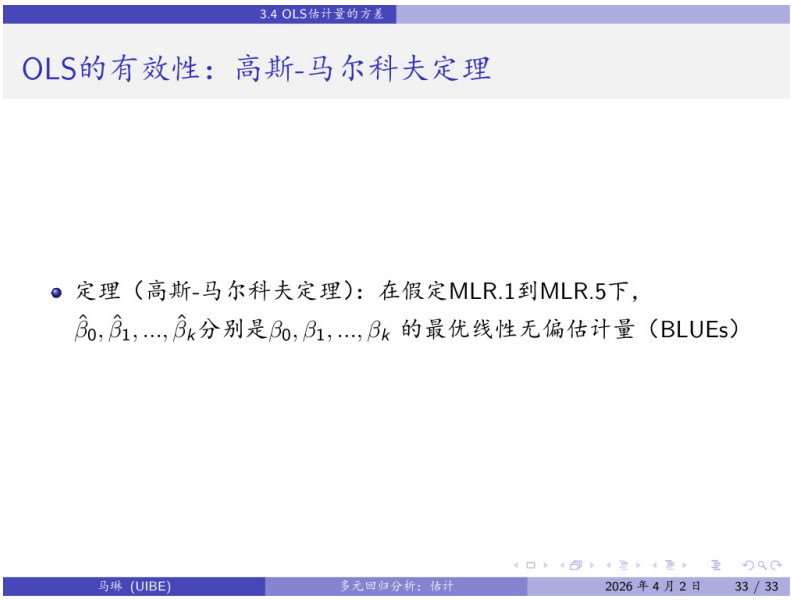

图 8: 高斯-马尔科夫定理（第 33 页）

定理（高斯-马尔科夫定理）

在假定 MLR.1 至 MLR.5 下，$\hat{\beta}_0, \hat{\beta}_1, \ldots, \hat{\beta}_k$ 分别是 $\beta_0, \beta_1, \ldots, \beta_k$ 的**最优线性无偏估计量**（Best Linear Unbiased Estimators, **BLUEs**）。

BLUE 的含义：

- **Best（最优）**：在所有线性无偏估计量中方差最小（有效性）
- **Linear（线性）**：估计量是因变量的线性组合
- **Unbiased（无偏）**：$E(\hat{\beta}_j) = \beta_j$

4.6 Feynman Summary

方差告诉我们每次估计的”散布范围”有多大。高斯-马尔科夫定理保证了：在五个基本假定下，OLS 不仅是不偏的（平均命中靶心），而且是所有不偏方法中最精准的（散布范围最小）。但这不意味着某次特定估计就一定好——只是说如果你必须在所有”公平的”线性方法中选一个，OLS 是最好的选择。如果违背假定（如同方差性或外生性），BLUE 性质就不复存在了。

5 总结与知识框架

5.1 核心知识图谱

表 2: 本章核心内容一览

主题	要点
为啥用多元回归?	控制混杂因素、提升解释力、灵活函数形式；偏回归系数 $\partial E(y)/\partial x_j = \beta_j$
OLS 操作	最小化残差平方和；矩阵解 $\hat{\beta} = (X^T X)^{-1} X^T Y$；Frisch-Waugh 定理
OLS 解释	变化量公式 $\Delta\hat{y} = \sum \hat{\beta}_j \Delta x_j$；拟合值/残差性质；$R^2$ 与调整 R^2
OLS 假定	MLR.1–MLR.4 保证无偏性；MLR.5 同方差性
OLS 方差	$\mathrm{var}(\hat{\beta}_j) = \sigma^2/\mathrm{SST}_j(1-R_j^2)$；VIF 方差膨胀因子
Gauss-Markov	BLUE：最优线性无偏估计量

5.2 关键公式速查

模型：	$y_i = \beta_0 + \beta_1 x_{1i} + \cdots + \beta_k x_{ki} + u_i$
OLS 解：	$\hat{\boldsymbol{\beta}} = (X^T X)^{-1} X^T Y$
无偏性：	$E(\hat{\beta}_j) = \beta_j \quad \text{(MLR.1–4)}$
方差：	$\mathrm{var}(\hat{\beta}_j) = \dfrac{\sigma^2}{\mathrm{SST}_j(1-R_j^2)} = \dfrac{\sigma^2}{\mathrm{SST}_j}\mathrm{VIF}_j$
R^2：	$R^2 = \mathrm{SSE}/\mathrm{SST} = 1 - \mathrm{SSR}/\mathrm{SST}$
调整 R^2：	$\bar{R}^2 = 1 - (1-R^2)\dfrac{n-1}{n-k-1}$
SER：	$\hat{\sigma}^2 = \dfrac{\sum \hat{u}_i^2}{n-k-1}$

6 苏格拉底对话

Q1：多元回归中变量个数 k 越大越好吗？

提示

不是。虽然增加变量通常提高 R^2，但也带来问题：(1) 自由度减少，估计精度下降；(2) 多重共线性风险增加，VIF 升高导致方差膨胀；(3) 可能引入无关变量造成过度拟合。应结合理论先验、调整 $\bar{R}^2$ 和显著性检验综合选择变量集。

Q2：R^2 很低（如 0.15）说明模型没用吗？

提示

不一定。R^2 低只说明当前解释变量对 y 变异的解释能力有限，但：(1) 如果某个关键系数统计显著且符号符合理论预期，模型仍有价值；(2) 在横截面数据（尤其是微观个体数据）中，低 R^2 很常见；(3) 因果推断的核心是系数的无偏性和一致性，而非 R^2 高低。

Q3：完全共线性和近似多重共线性有什么区别？实际中如何处理？

提示

完全共线性 $\Rightarrow X^TX$ 奇异，OLS 无解（如虚拟变量陷阱）。近似多重共线性 $\Rightarrow$ OLS 可估但方差变大、标准误膨胀、t 统计量下降。处理方法：(1) 增加样本容量（提高 SST）；(2) 剔除高度相关的冗余变量；(3) 使用主成分回归或岭回归等有偏估计方法；(4) 如果相关变量不是研究焦点，可以容忍较高的 VIF。

Q4：为什么说零条件均值（MLR.4）是最关键的假定？

提示

因为它直接决定了 OLS 的无偏性。若 $E(u|x) \neq 0$，意味着误差项包含与解释变量相关的信息（如遗漏了同时影响 y 和某个 x 的变量），此时 OLS 系数会把该变量的效果”归错”到已有系数上，产生**内生性偏差**。实际研究中检验外生性很困难，常依赖工具变量法（IV）、面板数据固定效应或自然实验来缓解。

Q5：高斯-马尔科夫定理中的”最优”是什么意思？有没有更好的非线性估计量？

提示

”最优”指在**所有线性无偏估计量**中方差最小。如果放宽”线性”约束（如极大似然估计 MLE 在正态假定下比 OLS 更有效），或放弃”无偏”要求（如岭回归牺牲无偏性换取更低方差），确实可能得到”更好”的估计量。高斯-马尔科夫定理的价值在于：它不需要分布假定（如正态性），仅依赖一阶和二阶矩条件就能保证 OLS 的最优性。